

Reducción de Dimensionalidad de Datos

1. Introducción.

En la sección anterior se explicó que cada observación puede representarse mediante un vector de características. Si una observación se describe utilizando p variables:

$$x = (x_1, x_2, \dots, x_p)$$

entonces cada observación ocupa una posición dentro de un espacio de p dimensiones.

Por ejemplo:

- 2 variables → espacio bidimensional.
- 3 variables → espacio tridimensional.
- 100 variables → espacio de 100 dimensiones.

Desde el punto de vista matemático no existe ninguna dificultad para trabajar en espacios de muchas dimensiones. Los algoritmos pueden realizar cálculos en cientos o miles de dimensiones.

Sin embargo, aparecen dos problemas fundamentales.

- Problema 1: Limitación humana

Los seres humanos solo pueden visualizar directamente una dimensión; dos dimensiones; tres dimensiones. Cuando un conjunto de datos contiene decenas o cientos de variables, resulta imposible observar directamente su organización espacial.

No podemos visualizar: agrupamientos; separaciones; anomalías; patrones geométricos. porque ocurren en un espacio que excede nuestra capacidad perceptual.

- Problema 2: La maldición de la dimensionalidad

A medida que aumenta el número de dimensiones, las observaciones tienden a dispersarse dentro del espacio de características. Como consecuencia:

- las distancias se vuelven menos informativas;
- la noción de vecindad se degrada;
- muchos algoritmos pierden efectividad.

Este fenómeno se conoce como maldición de la dimensionalidad y será analizado posteriormente con mayor detalle.

Por estas razones resulta útil construir una representación más compacta de los datos. La idea consiste en describir las observaciones utilizando menos dimensiones, intentando conservar los patrones relevantes presentes en el espacio original. Este proceso recibe el nombre de reducción de dimensionalidad.

2. Qué es reducción de dimensionalidad

La reducción de dimensionalidad consiste en construir una nueva representación de los datos utilizando menos dimensiones que las originales. Si originalmente una observación se representa como:

$$x = (x_1, x_2, \dots, x_p)$$

el objetivo es obtener una nueva representación:

$$z = (z_1, z_2, \dots, z_d)$$

donde: $d \ll p$

Es decir, el número de dimensiones de la nueva representación es mucho menor que el número original de variables.

Reducir dimensiones no significa conservar toda la información. Esto sería imposible. Cuando se pasa de 100 dimensiones a 2 dimensiones necesariamente se pierde información.

La pregunta importante no es "¿Cómo conservar toda la información?" sino: "¿Qué información es importante conservar?"

Toda técnica de reducción dimensional intenta conservar alguna estructura presente en los datos. Dependiendo del objetivo, la estructura relevante puede ser diferente. Por ejemplo:

- Preservar distancias. Interesa que observaciones que estaban próximas continúen próximas. Y que observaciones alejadas continúen alejadas.
- Preservar agrupamientos. Interesa mantener la separación entre grupos. Por ejemplo: clientes frecuentes, clientes ocasionales, clientes inactivos.
- Preservar vecindades. Interesa conservar quiénes son los vecinos más cercanos de cada observación.
- Preservar variabilidad. Interesa conservar las direcciones donde los datos presentan mayor variación. Esta es precisamente la idea utilizada por PCA.

Antes de estudiar algoritmos específicos es necesario distinguir dos conceptos fundamentales.

- a) Estructura local. Describe las relaciones de vecindad entre puntos cercanos en el espacio original. La pregunta es: ¿Quiénes son los vecinos más próximos de cada observación?

Por ejemplo: Si dos estudiantes poseen características muy similares, una técnica que preserve estructura local intentará mantenerlos próximos después de la reducción.

- b) Estructura global. Describe la organización general del conjunto de datos. La pregunta es: ¿Cómo están distribuidos los grupos dentro del espacio?

Por ejemplo: qué grupos existen; qué tan separados están; cuál es la forma general de los datos.

Muchos errores de interpretación ocurren porque se asume que todos los algoritmos preservan ambas estructuras simultáneamente. Esto no es cierto. Algunos algoritmos priorizan la estructura global. Otros priorizan la estructura local. Y algunos intentan equilibrar ambas.

3. Métodos lineales y no lineales.

Los métodos de reducción dimensional pueden dividirse en dos grandes grupos.

- a) Métodos lineales. Construyen nuevas dimensiones mediante combinaciones lineales de las variables originales. Son: más simples; más interpretables; más rápidos. El ejemplo más importante es PCA.
- b) Métodos no lineales. Buscan estructuras más complejas. Pueden descubrir patrones que los métodos lineales no detectan. Ejemplos: t-SNE; UMAP. Son especialmente útiles cuando los datos presentan formas complejas o manifolds no lineales.

4. Métodos de reducción de dimensionalidad

a) Análisis de Componentes Principales (PCA).

Recordemos que cada observación puede interpretarse como un punto dentro del espacio de características. PCA analiza la distribución geométrica de esos puntos y busca responder:

- ¿En qué dirección varían más los datos?

La primera dirección encontrada recibe el nombre de: Primer Componente Principal. Esta dirección corresponde al eje sobre el cual la dispersión de los datos es máxima.

Una vez encontrada esa dirección, PCA busca una segunda dirección que: explique la mayor variabilidad restante y sea perpendicular a la primera. Esta dirección recibe el nombre de: Segundo Componente Principal. El proceso continúa sucesivamente hasta obtener tantos componentes como variables originales.

Un **componente principal** no es una variable observada. Es una nueva variable construida a partir de las variables originales. Por ejemplo, si describimos estudiantes mediante: edad, promedio y asistencia. El primer componente podría construirse como una combinación de las tres variables. Cada componente resume información presente en varias variables

simultáneamente. Por esta razón, los componentes principales pueden interpretarse como nuevas dimensiones del espacio de representación.

Construcción matemática.

Supongamos una matriz de datos: X
compuesta por:

- n observaciones;
- p variables.

PCA construye nuevas dimensiones llamadas componentes principales. Cada componente se define como una combinación lineal de las variables originales. El primer componente se construye de manera que capture la mayor cantidad posible de variabilidad presente en los datos. El segundo componente captura la mayor variabilidad restante y debe ser ortogonal al primero. Matemáticamente, PCA obtiene estas direcciones a partir de la matriz de covarianza de los datos. Los autovectores de dicha matriz definen las direcciones principales. Los autovalores indican cuánta variabilidad explica cada dirección.

Uno de los conceptos más importantes de PCA es la varianza. La varianza representa la cantidad de dispersión presente en los datos. Cada componente principal explica una fracción de la variabilidad total.

Por ejemplo:

Componente	Varianza explicada
CP1	60%
CP2	25%
CP3	10%
CP4	5%

En este caso: $CP1 + CP2 = 85\%$ de la variabilidad total.

Esto significa que podríamos representar los datos utilizando únicamente dos componentes y conservar gran parte de la información original.

- Interpretación de una visualización PCA

Cuando representamos las observaciones utilizando los dos primeros componentes principales:

- cada punto sigue representando una observación;
- los ejes ya no corresponden a variables originales;
- los ejes corresponden a componentes principales.

Esto implica que: **el eje horizontal ya no representa edad, ingreso o temperatura.** Representa una combinación matemática de múltiples variables. Por esta razón, interpretar un gráfico PCA requiere analizar qué variables contribuyen más a cada componente.

- Ventajas de PCA

PCA presenta varias ventajas importantes:

- reduce dimensionalidad;
- elimina redundancia entre variables;
- facilita la visualización;
- disminuye ruido;
- mejora la eficiencia computacional;
- produce resultados deterministas.

Además, constituye una de las técnicas más utilizadas para exploración visual de datos multidimensionales.

- Limitaciones de PCA:

- Solo captura relaciones lineales, PCA busca direcciones rectas dentro del espacio de características. Si los datos presentan estructuras curvas o complejas, PCA puede producir representaciones distorsionadas.
- Sensibilidad a la escala. Si las variables utilizan escalas diferentes, las variables de mayor magnitud dominarán el análisis. Por esta razón, normalmente se aplica: Z-Score; Min-Max; Robust Scaling, antes de ejecutar PCA.

PCA constituye una de las técnicas más utilizadas para visualizar datos multidimensionales porque permite:

- construir representaciones bidimensionales o tridimensionales;
- identificar agrupamientos;
- detectar anomalías;
- analizar relaciones entre observaciones;
- explorar estructuras globales del conjunto de datos.

Sin embargo, es importante recordar que PCA prioriza la preservación de la estructura global asociada a la variabilidad de los datos. Por ello, suele ser adecuado para comprender la organización general del conjunto de datos, pero puede no ser la mejor opción cuando el interés principal se centra en preservar relaciones locales complejas entre observaciones cercanas.

b) Escalamiento Multidimensional (MDS)

Tipo: Puede ser lineal (clásico) o no lineal (no métrico). Conserva: Distancias originales entre pares de objetos.

MDS es una familia de técnicas estadísticas diseñadas para analizar y visualizar la estructura inherente en un conjunto de medidas de proximidad, como similitudes o disimilitudes entre pares de objetos, representando esos objetos como puntos en un espacio de baja dimensión, donde las distancias entre puntos correspondan lo más cercanamente posible a las proximidades observadas. Este enfoque permite el descubrimiento de dimensiones subyacentes que explican los patrones relacionales de los datos.

MDS se puede definir en términos de la minimización de una función de pérdida llamada "Stress", que es simplemente una medida de la falta de ajuste entre las disimilitudes D_{ij} y las distancias ajustadas $|x_i - x_j|$.

Ventaja: Proporciona una interpretación intuitiva, donde la proximidad espacial refleja directamente la similitud entre objetos.

Limitación: Computacionalmente costoso para conjuntos de datos grandes.

c) t-SNE (t-Distributed Stochastic Neighbor Embedding)

Visualiza datos de alta dimensión otorgando a cada punto una ubicación en un mapa de dos o tres dimensiones. La técnica es una variación de Stochastic Neighbor Embedding que es mucho más fácil de optimizar y produce visualizaciones significativamente mejores al reducir la tendencia a aglomerarse puntos en el centro del mapa. t-SNE es superior a las técnicas existentes para crear un mapa único que revela estructura a muchas escalas diferentes. Esto es particularmente importante para datos de alta dimensión que residen en varios *manifolds* de baja dimensión diferentes pero relacionados.

El algoritmo opera en dos pasos fundamentales:

- t-SNE funciona primero calculando, para cada par de puntos, la probabilidad de que los dos puntos sean similares basándose en su distancia euclidiana. El objetivo entonces es encontrar los valores correspondientes de baja dimensión para estos puntos que preserven la misma probabilidad.

- SNE determina estos valores minimizando la suma de divergencias de Kullback-Leibler sobre todos los puntos de datos. t-SNE difiere de SNE en la elección de la distribución de probabilidad exacta que define la similitud entre puntos (usando una distribución t de Student en lugar de una gaussiana).

t-SNE se ha convertido en el estándar de facto para visualizar conjuntos de datos de alta dimensión, con aplicaciones diversas como seguridad informática, análisis musical, biología del cáncer y bioinformática.

El parámetro principal es la perplejidad que revela diferentes aspectos de los datos. Perplejidad es el balance entre preservar la estructura global y local de los datos. Es aproximadamente una estimación del número de vecinos cercanos que tiene cada punto. Por lo tanto, un dataset más denso usualmente requiere un valor de perplejidad más alto. Se recomienda que esté entre 5 y 50.

Perplexity	Efecto	Cuándo usar
5-15	Valores bajos (5-15) crean vecindarios más localizados.	Datasets pequeños; exploración de estructura local fina
30 (default)	Un valor por defecto común es 30, que típicamente balancea bien la estructura local y global para la mayoría de datasets.	Punto de partida recomendado
30-50	Valores altos (30-50) crean vecindarios más amplios.	Datasets grandes; vista más global

Ventaja: Excelente separación visual de grupos en datos complejos.

Limitaciones: Las distancias entre clusters en la representación pueden no ser significativas (sólo las relaciones de vecindad local son confiables); los resultados son estocásticos y dependen del hiperparámetro de perplejidad; no es adecuado para preservar estructura global.

Error común a evitar: El mayor error que se comete con t-SNE es usar solo un valor de perplejidad y no probar cómo cambian los resultados con otros valores. Deben probar al menos 3 valores diferentes (e.g., 5, 30, 50) y comparar las visualizaciones resultantes.

d) UMAP (Uniform Manifold Approximation and Projection)

Tipo: No lineal. Conserva: Estructura local y parcialmente global.

UMAP es una técnica novedosa de aprendizaje de manifolds para reducción de dimensionalidad. UMAP está construido a partir de un marco teórico basado en geometría riemanniana y topología algebraica. El resultado es un algoritmo práctico y escalable que se aplica a datos del mundo real.

El algoritmo UMAP es competitivo con t-SNE en calidad de visualización, y se puede argumentar que preserva más de la estructura global con un rendimiento en tiempo de ejecución superior. Además, UMAP no tiene restricciones computacionales sobre la dimensión del embedding, lo que lo hace viable como una técnica de reducción de dimensionalidad de propósito general para aprendizaje automático.

El proceso de UMAP consta de dos etapas: (1) Construir un grafo ponderado entre nodos (puntos de datos) donde los pesos representan la probabilidad de que dos puntos estén conectados, con un balance entre consideraciones globales y locales. Localmente, los pesos se calculan de modo que un punto esté "cerca" de sus n vecinos más cercanos. Globalmente, se reduce la probabilidad de conexión a medida que crece la distancia. (2) Optimizar un grafo de baja dimensión para que sea estructuralmente lo más similar posible al grafo de alta dimensión.

Parámetros:

Parámetro	Rango recomendado	Default	Efecto de valores bajos	Efecto de valores altos
n_neighbors	5-100	15	Más detalle local; posible fragmentación	Más estructura global; menos detalle local
min_dist	0.0-1.0	0.1	Clusters densos y compactos	Clusters dispersos y separados

Ventajas: Rapidez y escalabilidad superiores a t-SNE; mejor preservación de estructura global; aplicable a dimensiones de embedding arbitrarias.

Limitaciones: Sensible a hiperparámetros (nneighbors, mindist); los fundamentos teóricos, aunque sólidos, son matemáticamente complejos.

Tabla comparativa

Criterio	PCA	t-SNE	UMAP	MDS
Tipo	Lineal	No lineal	No lineal	Lineal / No lineal
Preserva	Estructura global (varianza)	Estructura local	Local + parcialmente global	Distancias originales
Parámetros clave	n_components	perplexity (5-50)	nneighbors (5-100), mindist (0.0-1.0)	n_components, métrica
Velocidad	Muy rápido	Moderado-Lento	Rápido	Lento
Determinista	Sí	No (estocástico)	No (estocástico)	Sí (clásico)
Limitación principal	No captura relaciones no lineales	Distancias entre clusters no son significativas	Sensible a hiperparámetros	Costoso computacionalmente