

4. Visualización y Visual Analytics

La visualización de datos es un componente esencial del ciclo de ciencia de datos.

La visualización de datos no es solo representar datos en gráficos. El **visual analytics** es la ciencia de combinar técnicas analíticas con representaciones visuales interactivas para permitir al analista razonar sobre datos complejos. La visualización actúa como un amplificador cognitivo: externaliza el procesamiento de información hacia el sistema visual humano, que puede detectar patrones, agrupaciones y anomalías de forma que el análisis puramente numérico no puede.

4.1. Tipos de Visualización

La elección del tipo de gráfico depende de la naturaleza de los datos y de la pregunta analítica que se desea responder. A continuación se describen los principales tipos, incluyendo tanto los usados en análisis exploratorio como los específicos de visual analytics para datos de alta dimensión.

4.1.1. Visualización para relaciones y distribuciones

- a. **Scatterplot (diagrama de dispersión)**: cada observación es un punto en el plano cartesiano, donde su posición en x e y codifica dos variables. Visualiza la relación entre dos variables continuas. Permite identificar correlaciones, clusters y outliers. Cuando se combina con reducciones dimensionales (PCA, t-SNE, UMAP), permite explorar la estructura de datos multidimensionales en 2D. Cada eje ya no es una variable original sino una dimensión reducida.
- b. **Histogramas**: divide el rango de una variable numérica en intervalos (bins) y muestra la frecuencia de observaciones en cada uno. Permite ver asimetría, bimodalidad, rangos de valores y la presencia de outliers.
- c. **Boxplots (diagramas de caja y bigotes)**: Resumen de la distribución de una variable numérica con cinco estadísticos: mínimo, Q_1 (percentil 25), mediana (Q_2), Q_3 (percentil 75) y máximo (o límite de bigotes en $\pm 1.5 \cdot IQR$). Los puntos fuera de los bigotes son outliers. Es especialmente útil para comparar distribuciones entre múltiples grupos.
- d. **Heatmaps (mapas de calor)**: Representan matrices de valores mediante una escala de color. En análisis de datos multidimensionales se usa principalmente para matrices de correlación (cada celda muestra la correlación entre dos variables), matrices de similitud entre observaciones, o patrones de activación en datos temporales.
- e. **Violin plot**: combina el boxplot con la densidad de probabilidad estimada (kernel density estimation). Muestra no solo los percentiles sino la forma completa de la distribución, incluyendo bimodalidad que el boxplot no revela.

4.1.2. Visualización para datos multidimensionales (Visual Analytics)

- a. **Coordenadas paralelas**: cada variable se representa como un eje vertical y equidistante, y cada observación como una polilínea que conecta su valor en cada eje. Con p variables se tienen p ejes paralelos. Permite visualizar todos los atributos simultáneamente, identificar patrones (grupos de líneas paralelas indican observaciones similares), outliers (líneas que cruzan todas las demás) y correlaciones (ejes adyacentes con líneas paralelas = correlación positiva; líneas que se cruzan = correlación negativa). Es la visualización central de visual analytics para datos de alta dimensión.
- b. **RadViz**: proyecta observaciones multidimensionales en un círculo. Las variables se distribuyen como puntos equidistantes en la circunferencia y cada observación se representa como un punto dentro del círculo, cuya posición es el resultado del "tirón" de cada variable sobre ella.

(proporcional al valor de esa variable). Observaciones similares tienden a aparecer en la misma región del círculo.

- c. **Treemap**: representa datos jerárquicos como rectángulos anidados. El área de cada rectángulo es proporcional a una variable cuantitativa (por ejemplo, ingresos totales). El color puede codificar otra variable (por ejemplo, variación porcentual). Permite comparar proporciones en estructuras jerárquicas (categorías → subcategorías → ítems).
- d. **Gráfico de cuerdas** (Chord diagram): visualiza relaciones (flujos, conexiones) entre un conjunto de entidades dispuestas en un círculo. El ancho de cada cuerda es proporcional a la magnitud del flujo entre dos entidades. Útil para matrices de flujo (migraciones, exportaciones, interacciones entre grupos).
- e. **Gráfico de fuerza dirigido** (Force-directed graph): visualiza redes (grafos) donde los nodos son observaciones o entidades y las aristas representan relaciones entre ellas. Las posiciones de los nodos se calculan simulando fuerzas de atracción (aristas) y repulsión (todos los nodos). Los nodos muy conectados entre sí tienden a agruparse.
- f. **Sunburst / Icicle chart**: variantes radial y lineal del treemap para datos jerárquicos. El nivel jerárquico se representa por el radio (sunburst) o la posición vertical (icicle). Permiten navegar por múltiples niveles de una jerarquía.
- g. **Stream graph** (Gráfico de flujo): variante del gráfico de área apilada donde las capas se distribuyen simétricamente alrededor de un eje central. Muestra la evolución temporal de múltiples categorías simultáneamente y sus proporciones relativas.
- h. **Contour plot / Density map**: cuando el scatterplot tiene muchos puntos superpuestos (overplotting), un mapa de densidad estima la densidad de puntos en cada región y la representa con curvas de nivel o gradiente de color. Permite ver la estructura de distribución de los datos sin que los puntos se oscurezcan entre sí.
- i. **Matrices de dispersión (scatterplot matrix)**: Muestran todos los pares posibles de variables en una cuadrícula de diagramas de dispersión, facilitando la exploración exhaustiva de relaciones bivariadas.

4.2. Técnicas de Interacción

La interacción permite al analista explorar los datos de manera dinámica, pasando de una visión general a detalles específicos. Las técnicas fundamentales incluyen:

- a. **Zoom**: Permite acercar una región de interés para examinar detalles.
- b. **Pan (desplazamiento)**: Permite desplazar la vista manteniendo el nivel de zoom.
- c. **Tooltip (información emergente)**: Muestra detalles de una observación al posicionar el cursor sobre ella.
- d. **Filtering (filtrado)**: Permite mostrar únicamente subconjuntos de datos que cumplen criterios específicos.
- e. **Brushing (selección interactiva)**: Es un mecanismo para seleccionar interactivamente subconjuntos de datos de manera que puedan ser resaltados, eliminados o enmascarados.
- f. **Linking (vinculación)**: Comprende dos etapas secuenciales, donde las selecciones realizadas en una visualización (brushing) se muestran automáticamente en otra visualización (linking).

Interacción	Qué hace exactamente	Propósito analítico
Zoom	Amplía una región del gráfico, agrandando los puntos y el espacio entre ellos.	Examinar grupos densos o puntos próximos que a escala global no se distinguen.
Pan	Desplaza la vista sin cambiar el nivel de zoom.	Navegar por regiones del espacio cuando se está en zoom aumentado.
Tooltip	Muestra información del punto sobre el que está el cursor, sin necesidad de hacer click.	Obtener detalles bajo demanda sin saturar la vista principal.
Selección puntual	Click en un punto individual; se resalta ese punto y se muestran sus datos.	Inspeccionar una observación específica.
Brush (pincel)	El usuario dibuja un rectángulo o lazo sobre el gráfico; todos los puntos dentro quedan seleccionados.	Seleccionar un subconjunto de observaciones para análisis comparativo.
Filtrado	Oculta observaciones que no cumplen un criterio (slider de rango, checkbox de categoría).	Aislar subpoblaciones de interés y reducir el ruido visual.

4.3. Vistas coordinadas (Coordinated Multiple Views)

El linking and brushing es una técnica esencial para la exploración y análisis interactivo de datos que aprovecha múltiples vistas coordinadas para identificar, seleccionar y combinar puntos de datos de interés.

Los sistemas de vistas coordinadas (Coordinated Multiple Views, CMV) presentan los mismos datos a través de múltiples representaciones visuales sincronizadas. El principio fundamental es que una selección (brush) realizada en cualquiera de las vistas se propaga automáticamente a todas las demás, permitiendo al analista explorar relaciones complejas entre variables desde múltiples perspectivas simultáneamente.

Por ejemplo, un analista puede seleccionar un grupo de puntos en un scatterplot de la proyección PCA y observar inmediatamente cómo se distribuyen esos mismos puntos en un histograma de ingresos, un boxplot de edades y un mapa geográfico. Esta capacidad de exploración multifacética es lo que distingue al visual analytics de la visualización estática.

Vista	Tipo de gráfico	Objetivo analítico	Qué observar
Scatterplot 2D	Diagrama de dispersión de la proyección	Explorar similitudes y agrupaciones entre observaciones	Clusters, outliers, patrones de proximidad
Histograma	Distribución de frecuencias por variable	Analizar la distribución de una variable numérica para los puntos seleccionados	Asimetría, bimodalidad, rango de valores
Heatmap	Mapa de calor de correlaciones o valores	Visualizar patrones en matrices de correlación entre variables	Variables altamente correlacionadas, bloques de correlación
Coordenadas paralelas	Ejes paralelos verticales con polilíneas	Analizar simultáneamente múltiples variables de los puntos seleccionados	Patrones comunes, cruces anómalos, rangos de variables