

Transformación de Datos

1. Introducción

Todo proceso de análisis de datos comienza con una pregunta sobre un fenómeno del mundo real. Un fenómeno puede corresponder a contextos muy diversos, como la calidad del aire de una ciudad, el comportamiento de clientes en una empresa, el estado de salud de pacientes en un hospital o el rendimiento académico de estudiantes universitarios

Sin embargo, los algoritmos no pueden analizar directamente estos fenómenos. Un algoritmo no puede analizar una ciudad, un paciente o un estudiante. Lo único que puede procesar son representaciones matemáticas de esos objetos. Por esta razón, el primer problema fundamental de la Ciencia de Datos consiste en construir una representación matemática adecuada del fenómeno que se desea estudiar.

Esta etapa suele recibir menos atención que los algoritmos de aprendizaje automático o las técnicas de visualización. Sin embargo, desde una perspectiva científica, constituye una de las decisiones más importantes de todo el proceso analítico. Una representación inadecuada puede ocultar patrones relevantes, introducir relaciones artificiales o distorsionar la estructura real de los datos. En consecuencia, incluso los algoritmos más sofisticados producirán resultados deficientes si operan sobre una representación incorrecta del fenómeno.

Antes de preguntarnos qué algoritmo utilizar, debemos responder una pregunta más fundamental:

¿Cómo puede representarse matemáticamente un fenómeno del mundo real para que sus propiedades relevantes puedan ser analizadas computacionalmente?

2. Espacio de características y representación matemática

2.1. Observaciones, variables y datos.

Todo conjunto de datos constituye una representación simplificada de un fenómeno del mundo real. Un fenómeno puede corresponder a contextos muy diversos, como la calidad del aire de una ciudad, el comportamiento de clientes en una empresa, el estado de salud de pacientes en un hospital o el rendimiento académico de estudiantes universitarios.

En Ciencia de Datos, los datos suelen organizarse en forma tabular. Esta estructura permite almacenar información de manera ordenada y facilita su procesamiento computacional. Una tabla de datos está compuesta por filas y columnas. Cada fila representa una observación y cada columna representa una variable.

Una **observación** corresponde a una instancia particular del fenómeno estudiado. Dependiendo del problema de análisis, una observación puede representar un estudiante, un paciente, un cliente, una vivienda, una transacción financiera o una medición realizada por una estación de monitoreo ambiental. Por ejemplo, si el objetivo es analizar el rendimiento académico universitario, cada estudiante constituye una observación.

Sin embargo, una observación por sí sola no proporciona información suficiente para realizar un análisis. Es necesario describirla mediante un conjunto de características observables o medibles. Estas características reciben el nombre de variables. Las **variables** representan propiedades utilizadas para describir una observación. En el caso de estudiantes universitarios, algunas variables podrían ser: edad, promedio académico, número de cursos aprobados, porcentaje de asistencia, horas de estudio semanales.

Mientras las observaciones representan los objetos que se desean estudiar, las variables representan las propiedades utilizadas para describir dichos objetos. Cada variable captura una dimensión específica del fenómeno estudiado y permite diferenciar unas observaciones de otras. El valor que toma una variable para una observación específica recibe el nombre de **dato**.

La diferencia entre estos tres conceptos puede comprenderse mediante el siguiente ejemplo:

Estudiante	Edad	Promedio	Asistencia
E001	20	15.3	92
E002	22	14.1	85
E003	19	16.8	97

En esta tabla:

- Cada estudiante corresponde a una **observación**.
- Edad, promedio y asistencia son **variables**.
- El valor 20 es un **dato**.

De forma general:

- Una observación responde a la pregunta: ¿qué objeto o caso estamos analizando?
- Una variable responde a la pregunta: ¿qué característica estamos midiendo?
- Un dato responde a la pregunta: ¿qué valor tomó esa característica para esa observación?

Esta distinción es fundamental porque todo análisis posterior se construye a partir de las relaciones existentes entre observaciones y variables. Los algoritmos de clasificación, agrupamiento, reducción de dimensionalidad y análisis visual no operan directamente sobre fenómenos reales, sino sobre observaciones descritas mediante variables y representadas mediante datos.

2.2. De las observaciones a los vectores

Una vez definidas las variables, cada observación puede representarse mediante una colección ordenada de valores. Supongamos un estudiante descrito por cinco variables:

Variable	Edad	Promedio	Cursos aprobados	Asistencia	Horas de estudio
Valor	20	14.5	35	0.92	18

Desde el punto de vista matemático, esta información puede representarse mediante un vector. Un **vector** es una estructura ordenada de valores numéricos utilizada para describir una observación.

En este caso, el estudiante puede representarse como:

$$x = (20, 14.5, 35, 0.92, 18)$$

Cada posición del vector corresponde a una variable específica. Por tanto, un vector no es simplemente una lista de números. Es una representación matemática estructurada de una observación.

2.3. El vector de características.

En Ciencia de Datos, el vector utilizado para representar una observación recibe el nombre de vector de características (*feature vector*).

El término **característica** se refiere a cualquier propiedad utilizada para describir una observación.

Por ejemplo, si una observación se describe mediante cinco variables: edad, promedio, cursos aprobados, asistencia y horas de estudio. El vector de características estará compuesto por esas cinco características. El conjunto de características seleccionadas determina la información que estará disponible para cualquier análisis posterior.

Los algoritmos aprenden de las características que los analistas deciden incluir en el vector de representación. Si una característica relevante no está presente en el vector, el algoritmo no podrá utilizarla. Por esta razón, la construcción del vector de características constituye una decisión epistemológica además de técnica. El vector define qué aspectos de la realidad serán observables para el sistema analítico y cuáles permanecerán ocultos.

2.4. El conjunto de datos como una matriz

En la práctica no analizamos una única observación, sino miles o millones de ellas. Si cada observación se representa mediante un vector de características, todos los vectores pueden organizarse en una estructura tabular denominada matriz de datos.

En esta matriz:

- Cada fila representa una observación.
- Cada columna representa una variable.

Por ejemplo:

Estudiante	Edad	Promedio	Cursos aprobados	Asistencia	Horas de estudio
1	20	14.5	35	0.92	18
2	22	13.8	30	0.85	15
3	19	16.2	40	0.97	22

Desde una perspectiva matemática, esta tabla constituye una matriz de datos.


Si existen: **n** observaciones y **p** variables, entonces la matriz posee n filas y p columnas. Esta representación matricial constituye el punto de partida para la mayoría de técnicas de análisis de datos, aprendizaje automático y visualización.

2.5. El concepto de dimensión y espacio de características.


Una vez que las observaciones han sido representadas mediante vectores de características, surge un concepto fundamental para comprender la mayoría de técnicas de Ciencia de Datos y Análisis Visual: **la dimensión**.

Cada variable define una **dimensión** del espacio de características. Por tanto, el número de dimensiones depende del número de variables utilizadas para describir cada observación.


Por ejemplo, consideremos inicialmente un conjunto de estudiantes descritos únicamente mediante la variable edad. En este caso, cada observación se describe mediante un único valor. Como solamente existe una variable, el espacio de representación posee una dimensión. Matemáticamente, cada estudiante puede representarse mediante una única coordenada asociada a su edad. Una coordenada es un valor que permite especificar la posición de una observación dentro de un espacio de representación. Debido a que solo existe una coordenada, las observaciones pueden ubicarse sobre una recta numérica.



Ahora supongamos que cada observación requiere ahora dos valores para ser descrita completamente: edad e ingreso. Estos valores constituyen dos coordenadas que permiten determinar la posición de la observación dentro del espacio de representación. Como existen dos variables, el espacio posee dos dimensiones y las observaciones pueden representarse como puntos en un plano.



Si incorporamos una tercera variable, por ejemplo experiencia laboral, cada observación requerirá tres coordenadas para ser representada completamente. En este caso, el espacio posee tres dimensiones y cada observación puede representarse como un punto en un espacio tridimensional.



De forma general, cada nueva variable agrega una dimensión adicional al espacio de representación. Por tanto, el número de dimensiones coincide con el número de variables presentes en el vector de características. Si un conjunto de datos contiene 100 variables, entonces cada observación se encuentra representada dentro de un espacio de 100 dimensiones y los algoritmos sí pueden operar matemáticamente sobre ellos.

El conjunto de todas las dimensiones definidas por las variables recibe el nombre de **espacio de características**. El espacio de características es el entorno geométrico donde se ubican todas las observaciones del conjunto de datos. Cada observación puede considerarse como un punto dentro de un espacio multidimensional definido por sus variables. A partir de esta representación será posible estudiar relaciones de similitud, distancia, agrupamiento y estructura de los datos, conceptos que constituyen la base de las técnicas de análisis visual y reducción de dimensionalidad.

2.6. Geometría de los datos y espacio latente.

Recordemos que cada observación está representada por un vector de características y que cada variable define una dimensión del espacio de características. Como consecuencia, cada observación puede interpretarse como un punto dentro de ese espacio. La geometría de los datos corresponde precisamente al estudio de la disposición espacial de estos puntos y de las relaciones espaciales que existen entre las observaciones representadas por dichos puntos.

La representación de las observaciones como puntos dentro del espacio de características permite estudiar relaciones espaciales entre ellas. Por ejemplo, si dos estudiantes presentan edades, promedios y niveles de asistencia similares, sus representaciones tenderán a ubicarse próximas entre sí. En cambio, estudiantes con características muy diferentes tenderán a ocupar posiciones más alejadas.

A partir de esta representación surgen conceptos fundamentales para el análisis de datos:

- **Similitud:** observaciones con características parecidas tienden a ubicarse próximas entre sí.
- **Distancia:** cuantifica el grado de diferencia entre observaciones.
- **Vecindad:** conjunto de observaciones cercanas a una observación determinada.
- **Agrupamiento:** conjunto de observaciones que ocupan una misma región del espacio debido a que comparten características similares.
- **Anomalía:** observación que aparece aislada respecto al resto de los datos.

Desde esta perspectiva, muchos problemas de análisis de datos pueden interpretarse como problemas de organización espacial. Identificar grupos, detectar anomalías o encontrar patrones equivale a analizar cómo se distribuyen las observaciones dentro del espacio de características.

Sin embargo, en problemas reales el espacio de características suele contener decenas, cientos o incluso miles de variables. Aunque los algoritmos pueden operar matemáticamente sobre estos espacios de alta dimensión, resulta difícil comprender visualmente su estructura. Por esta razón, con frecuencia se busca construir una nueva representación de los datos que conserve las relaciones más importantes entre las observaciones, pero utilizando un número menor de dimensiones. Esta nueva representación recibe el nombre de espacio latente.

Un **espacio latente** es un espacio construido a partir de nuevas dimensiones que no corresponden necesariamente a las variables originales observadas. Estas dimensiones son obtenidas mediante transformaciones matemáticas que buscan resumir, revelar o preservar patrones presentes en los datos. La idea fundamental consiste en describir el fenómeno utilizando una representación más compacta que mantenga la estructura geométrica relevante del conjunto de datos.

Por ejemplo, supongamos que una persona se describe mediante las siguientes variables: peso, porcentaje de grasa corporal, circunferencia abdominal, índice de masa corporal (IMC). Todas estas variables son observables porque pueden medirse directamente. Sin embargo, gran parte de la información contenida en ellas parece estar relacionada con un concepto más general: la condición física de la persona. Aunque la condición física no aparece explícitamente como una variable en la tabla de datos, puede considerarse un factor que resume parte de la información contenida en las variables observadas. Si describiéramos a las personas mediante dimensiones como: condición física y masa muscular, estaríamos utilizando una representación distinta de la original. Estas nuevas dimensiones no corresponden directamente a variables medidas, sino a factores que sintetizan patrones presentes en los datos. Esta representación constituye un ejemplo conceptual de espacio latente.

Es importante señalar que las dimensiones de un espacio latente no siempre poseen una interpretación tan clara como "condición física" o "masa muscular". En muchos métodos de reducción de dimensionalidad las nuevas dimensiones son construcciones matemáticas cuya función principal es preservar relaciones geométricas entre observaciones. Por esta razón, técnicas como PCA, MDS, t-SNE y UMAP pueden entenderse como métodos para construir espacios latentes de menor dimensión que intentan conservar aspectos relevantes de la geometría presente en el espacio original de características.

Comprender la diferencia entre espacio de características y espacio latente será fundamental para interpretar correctamente las visualizaciones generadas por estos métodos.

El espacio de características describe los datos usando las variables originales.

El espacio latente describe los mismos datos usando nuevas dimensiones construidas para resumir o preservar la estructura de los datos

3. Transformación de datos.

En la sección anterior se explicó que un conjunto de datos puede representarse mediante una matriz de observaciones y variables, donde cada observación corresponde a un punto dentro de un espacio de características. Sin embargo, los conjuntos de datos suelen contener valores faltantes, errores de registro, variables medidas en diferentes unidades, escalas incompatibles, categorías textuales, valores extremos o representaciones que no reflejan adecuadamente la estructura del fenómeno estudiado.

Estos problemas no solo afectan la calidad de los datos. También afectan la forma en que las observaciones se distribuyen dentro del espacio de características.

Para comprender esta idea, consideremos un conjunto de estudiantes descritos mediante tres variables:

Variable	Edad	Horas de estudio	Ingreso familiar
Valores típicos	18-30	0-40	500 - 10000

La diferencia de edad es de 1 año y la diferencia en horas de estudio es de 3 horas. Sin embargo, la diferencia en ingreso es de 4000 unidades monetarias. La variable ingreso dominará el cálculo simplemente porque utiliza valores numéricos mucho mayores. Como consecuencia, dos estudiantes podrían considerarse "similares" o "diferentes" principalmente por su ingreso, incluso cuando otras variables resulten igualmente importantes para el problema de análisis.

Este problema ilustra una idea fundamental: Los datos observados no siempre constituyen la mejor representación matemática del fenómeno.

Por esta razón, antes de aplicar técnicas de análisis, modelado o visualización, suele ser necesario modificar la representación original de los datos. A este proceso se le denomina transformación de datos.

Una **transformación** es una operación matemática que modifica la representación original de los datos. De forma general, una transformación puede representarse mediante una función:

$$T(X)$$

donde:

- X representa la matriz de los datos originales.
- T representa una función de transformación.
- $T(X)$ representa la nueva representación obtenida después de aplicar dicha transformación.

Es importante comprender que una transformación no modifica el fenómeno estudiado. Lo que modifica es la forma en que dicho fenómeno es representado matemáticamente. Transformar datos implica modificar la geometría de los datos. Recordemos que cada observación puede interpretarse como un punto dentro del espacio de características. Cuando modificamos los valores de las variables:

- cambian las coordenadas de los puntos,
- cambian las distancias,

- cambian las relaciones de vecindad,
- cambian los agrupamientos observables.

Por ejemplo, si una variable posee valores entre 0 y 10000 y otra entre 0 y 10, la variable de mayor escala dominará los cálculos de distancia. Después de aplicar una normalización, ambas variables contribuirán de manera más equilibrada al cálculo de similitudes y diferencias entre observaciones.

Desde una perspectiva geométrica, transformar los datos significa modificar la representación espacial de las observaciones dentro del espacio de características. Al cambiar los valores de las variables, también cambian las coordenadas de las observaciones, las distancias entre ellas, las relaciones de vecindad y, potencialmente, los agrupamientos presentes en los datos.

Esta idea es fundamental porque numerosos métodos de Ciencia de Datos y Análisis Visual, como los algoritmos de agrupamiento, los métodos basados en distancia y las técnicas de reducción de dimensionalidad, operan directamente sobre la geometría del espacio de características. En consecuencia, comprender cómo las transformaciones modifican la geometría de los datos permite interpretar correctamente los resultados producidos por los diferentes métodos y evaluar si la representación construida refleja adecuadamente la estructura del fenómeno estudiado.

3.1. Tratamiento de valores faltantes

¿Qué es un valor faltante? (missing data)

En un conjunto de datos, un valor faltante (missing value) corresponde a una situación en la que no se dispone del valor de una variable para una observación determinada.

Por ejemplo, consideremos la siguiente tabla:

Estudiante	Edad	Promedio	Horas de estudio
E001	20	15.3	18
E002	21	—	12
E003	19	16.8	20

En este caso, el promedio académico del estudiante E002 es desconocido. La información correspondiente a esa variable no se encuentra disponible y, por tanto, se considera un valor faltante.

Desde una perspectiva matemática, existe una observación y existe una variable, pero no se conoce el valor que debería ocupar esa posición dentro de la matriz de datos.

¿Por qué aparecen valores faltantes?

Los valores faltantes son extremadamente frecuentes en problemas reales y pueden originarse por múltiples causas. Algunas de las más comunes son:

- errores durante la captura de datos;
- fallos de sensores o dispositivos de medición;
- pérdida de registros durante el almacenamiento;
- formularios incompletos;
- preguntas que el usuario decidió no responder;
- Imposibilidad de realizar una medición.

Por ejemplo, en una encuesta sobre ingresos económicos algunas personas pueden decidir no revelar dicha información. En un sistema de monitoreo ambiental, un sensor puede dejar de funcionar temporalmente. En ambos casos aparecen valores faltantes, aunque las causas son completamente distintas.

Comprender el origen de la ausencia es importante porque determina cómo debe tratarse posteriormente.

¿Por qué los valores faltantes representan un problema?


La mayoría de algoritmos de análisis de datos y aprendizaje automático requieren valores completos para realizar cálculos. Por ejemplo:

- no es posible calcular una distancia entre observaciones si algunas coordenadas son desconocidas;
- no puede calcularse una media utilizando valores inexistentes;
- muchos algoritmos de clasificación, agrupamiento y reducción de dimensionalidad no aceptan registros incompletos.

Además, la ausencia de información puede alterar la distribución de los datos y producir resultados sesgados si no se trata adecuadamente. Por esta razón, antes de realizar el análisis es necesario decidir cómo representar dicha ausencia de datos.

3.2. Métodos clásicos de valores faltantes.

Los métodos clásicos se dividen en dos ramas, eliminación e imputaciones:



3.2.1. Eliminar observaciones con valores faltantes

La estrategia más simple consiste en eliminar las observaciones incompletas.

Por ejemplo:

Estudiante	Edad	Promedio
E001	20	15.3
E002	21	—
E003	19	16.8

podría transformarse en:

Estudiante	Edad	Promedio
E001	20	15.3
E003	19	16.8

Esta estrategia resulta razonable cuando:

- la cantidad de valores faltantes es pequeña;
- las observaciones eliminadas representan una fracción reducida del conjunto de datos;
- no existe evidencia de que la ausencia esté asociada a algún patrón específico.

Sin embargo, eliminar observaciones implica descartar información. Si una gran proporción de registros contiene valores faltantes, la eliminación puede reducir significativamente el tamaño de la muestra y afectar la representatividad de los datos. Por esta razón, la eliminación debe considerarse una decisión analítica y no una operación automática.

3.2.2. Imputar valores faltantes


La imputación consiste en reemplazar un valor faltante por una estimación razonable. El objetivo no es recuperar el valor verdadero, que generalmente es desconocido, sino construir una representación completa que permita continuar el análisis.

Las estrategias más comunes son:

a) Imputar con la media.

Reemplazar los datos faltantes con la **media**.

Mean (Download Speed) = 130



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	N/A	95%
8	Lite	76	77%
9	Fast+	180	95%

Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	130	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	130	95%
8	Lite	76	77%
9	Fast+	180	95%

Solo utilice estos métodos si la porción de datos faltantes es baja.

Limitaciones: reduce la variabilidad, debilita las estimaciones de correlación porque ignora la relación entre las variables.

b) Imputar con la mediana

La mediana puede ser usada cuando las variables tienen una distribución asimétrica.

Median (Download Speed) = 155

Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	N/A	95%
8	Lite	76	77%
9	Fast+	180	95%



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	155	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	155	95%
8	Lite	76	77%
9	Fast+	180	95%

c) Imputar con la moda

La moda reemplaza las variables faltantes con el valor más frecuente, ya que es la ocurrencia más probable.

Mode (Download Speed) = 200

Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	200	80%
2	Lite	100	70%
3	Fast+	200	10%
4	Fast+	N/A	80%
5	Lite	50	70%
6	Fast+	200	10%
7	Fast+	N/A	95%
8	Lite	200	77%
9	Fast+	180	95%



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	200	80%
2	Lite	100	70%
3	Fast+	200	10%
4	Fast+	200	80%
5	Lite	50	70%
6	Fast+	200	10%
7	Fast+	200	95%
8	Lite	200	77%
9	Fast+	180	95%

d) Last Observation Carried Forward (LOFC)

Si los datos son series temporales, uno de los métodos utilizados es reemplazar los datos faltantes por la última observación realizada. Siempre que falte un valores, se reemplaza con el último valor observado,

Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	N/A	86%
6	6-Jan	155	87%
7	7-Jan	N/A	89%
8	8-Jan	N/A	90%
9	9-Jan	180	92%



Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	90	86%
6	6-Jan	155	87%
7	7-Jan	155	89%
8	8-Jan	155	90%
9	9-Jan	180	92%

Limitaciones: la estructura de covarianza y la distribución cambian seriamente.

e) Interpolación lineal

Los valores faltantes se completan usando una función para extrapolar los datos que faltan. Considerando las observaciones antes y después de ellos.

Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%

Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	N/A	86%
6	6-Jan	150	87%
7	7-Jan	160	89%
8	8-Jan	N/A	90%
9	9-Jan	180	92%



Limitaciones: si la tendencia es compleja, puede que no sea suficiente y no es apropiado para datos estacionales.

f) K-nn

Crea una lista completa para construir un kd-Tree. Usa el kd-tree para calcular los vecinos más cercanos. Encuentra los k-vecinos, tomando el valor promedio ponderado de ellos.

Ventajas: puede ser más exacto que la media, la mediana o métodos de imputación más frecuentes.

Limitaciones: computacionalmente costoso, almacena el conjunto de datos de entrenamiento en memoria, es muy sensible a outliers.

3.3. Tratamiento de valores faltantes

Los valores faltantes aparecen cuando no se dispone de información para una determinada variable en una o más observaciones. Sin embargo, no todas las ausencias tienen el mismo significado. Para decidir si una observación debe eliminarse, imputarse o analizarse de forma especial, es necesario comprender por qué falta la información.

Desde una perspectiva estadística, los mecanismos de ausencia suelen clasificarse en tres categorías

- **MCAR (Missing Completely At Random):** La probabilidad de que un registro dado tenga un elemento de datos faltante es la misma para todos los registros (es decir, el patrón de valores faltantes es completamente independiente de las variables restantes en el conjunto de datos). Por ejemplo, durante la digitalización de encuestas algunas páginas podrían haberse perdido accidentalmente debido a un error del sistema de almacenamiento. La pérdida de información no depende de las características de los participantes ni de los valores faltantes.
- **MAR (Missing At Random):** En la mayoría de los casos, el patrón de valores faltantes dependerá de otros factores observados dentro del conjunto de datos. Por ejemplo, supongamos una encuesta donde los estudiantes de último año responden con menor frecuencia preguntas relacionadas con horas de estudio. En este caso, la ausencia depende de una variable observada (año académico).
- **MNAR (Missing Not At Random):** Los casos restantes, donde el patrón de valores faltantes puede depender de factores no observados, o incluso de la magnitud del valor faltante en sí mismo, son difíciles de analizar y requieren modelado explícito. Por ejemplo, personas con ingresos muy altos podrían decidir no declarar sus ingresos en una encuesta. En este caso, la probabilidad de ausencia está directamente relacionada con el valor que falta.

4. Escalamiento de variables numéricas

En muchos conjuntos de datos, las variables se miden utilizando unidades y rangos numéricos diferentes. Por ejemplo, supongamos que deseamos describir estudiantes mediante las siguientes variables:

Variable	Unidad	Valores típicos
Edad	años	18 – 30
Horas de estudio	horas/semana	0 – 40
Ingreso familiar	soles/mes	500 – 10000

Aunque las tres variables describen características relevantes del fenómeno estudiado, sus magnitudes numéricas son muy distintas. La edad varía aproximadamente entre 18 y 30, las horas de estudio varían entre 0 y 40. Sin embargo, el ingreso familiar puede variar entre cientos o miles de unidades monetarias. Esta diferencia de escala puede producir problemas en algoritmos que utilizan distancias o relaciones de vecindad para comparar observaciones. Entre ellos se encuentran K-Means, K-Nearest Neighbors (KNN), PCA, MDS, t-SNE y UMAP .

Recordemos que cada observación puede representarse como un punto dentro del espacio de características. La distancia entre dos observaciones se calcula utilizando los valores de todas las variables.

Por ejemplo, consideremos dos estudiantes:

Variable	Estudiante A	Estudiante B
Edad	20	21
Horas de estudio	15	18
Ingreso familiar	1000	5000

Las diferencias entre ambos estudiantes son:

Variable	Diferencia
Edad	1
Horas de estudio	3
Ingreso familiar	4000

Obsérvese que la diferencia asociada al ingreso es mucho mayor que las demás. Como consecuencia, al calcular distancias, la variable ingreso tendrá una influencia dominante sobre la posición relativa de las observaciones. En otras palabras, el algoritmo considerará que dos estudiantes son similares o diferentes principalmente por su ingreso, incluso cuando otras variables también sean importantes para el fenómeno analizado. Este problema no surge porque el ingreso sea necesariamente más importante, sino porque utiliza una escala numérica mucho mayor.

Por esta razón, antes de aplicar algoritmos basados en distancia, suele ser necesario transformar las variables para evitar que las diferencias de escala alteren la geometría del espacio de características. Este proceso recibe el nombre de escalamiento de variables.

Escalar una variable consiste en transformar sus valores numéricos para que puedan compararse de manera más equilibrada con otras variables. El objetivo no es modificar el fenómeno estudiado, sino evitar que una variable determine casi por completo las distancias entre observaciones debido únicamente a su magnitud numérica.

4.1. Métodos.

a) Estandarización Z-Score

La estandarización Z-Score transforma una variable para que sus valores se expresen en función de cuántas desviaciones estándar la separan de la media. La transformación se define como:

$$x'_i = \frac{x_i - \mu}{\sigma}$$

donde:

x = valor original de la observación.

μ = media de la variable.

σ = desviación estándar de la variable. (La desviación estándar es una medida de dispersión que indica cuánto se alejan, en promedio, los valores respecto a la media. Valores pequeños indican que las observaciones se concentran cerca de la media; valores grandes indican mayor dispersión)

z = valor transformado.

La estandarización Z-Score reemplaza la unidad original de una variable por una nueva escala que indica qué tan lejos se encuentra cada observación respecto al valor promedio de la variable. Después de la transformación, un valor de

z = 0 indica que la observación coincide con la media.

z > 0 indica que la observación se encuentra por encima de la media.

z < 0 indica que la observación se encuentra por debajo de la media.

|z| indica cuántas desviaciones estándar separan a la observación de la media.

La estandarización suele utilizarse cuando: las variables poseen escalas diferentes; los algoritmos utilizan distancias; interesa comparar desviaciones relativas respecto a la media.

Limitación: La media y la desviación estándar son sensibles a valores atípicos. Por esta razón, unos pocos valores extremos pueden modificar significativamente la transformación.

b) Normalización Min-Max

La normalización Min-Max transforma los datos para que todos los valores queden dentro de un intervalo fijo, generalmente entre 0 y 1.

La transformación se define como:

$$x'_i = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

donde:

x = valor original.

x_min = valor mínimo observado.

x_max = valor máximo observado.

x' = valor transformado.

Después de la transformación: $0 \leq x' \leq 1$

La normalización Min-Max conserva el orden entre observaciones. Si una observación tenía un valor mayor que otra antes de la transformación, seguirá teniendo un valor mayor después de la transformación.

Se usa cuando:

- se desea trabajar con valores acotados;
- los algoritmos requieren rangos específicos;
- los datos no presentan valores extremos importantes.

Limitación: La transformación depende directamente de los valores mínimo y máximo. Si aparece un valor extremadamente grande o pequeño, el resto de observaciones puede quedar comprimido dentro de una región muy reducida del intervalo. Por ello, Min-Max es sensible a valores atípicos.

c) Robust Scaling

En muchos problemas los valores extremos representan observaciones reales y no deben eliminarse. Sin embargo, dichos valores pueden distorsionar transformaciones basadas en la media, la desviación estándar, el mínimo o el máximo. Para reducir este problema se utiliza Robust Scaling.

La transformación se define como:

$$x' = (x - \text{Mediana}) / \text{IQR}$$

donde:

Mediana = valor central de la distribución.

IQR = rango intercuartílico.

IQR = Q3 - Q1

Q1 = primer cuartil.

Q3 = tercer cuartil.

El rango intercuartílico representa la amplitud ocupada por el 50% central de las observaciones. Por ejemplo:

- el 25% de los datos se encuentra por debajo de Q1;
- el 25% se encuentra por encima de Q3;
- el 50% restante se encuentra entre ambos valores.

Como el IQR ignora los extremos de la distribución, resulta menos sensible a los outliers (valores atípicos).

Robust Scaling centra los datos alrededor de la mediana y utiliza el rango intercuartílico como medida de dispersión. De esta forma, como el IQR se calcula a partir de los cuartiles centrales de la distribución, su valor se ve mucho menos afectado por observaciones extremadamente grandes o pequeñas.

Suele ser la alternativa más apropiada cuando:

- existen valores atípicos;
- dichos valores representan fenómenos reales;
- no se desea eliminarlos;
- los algoritmos son sensibles a la escala de las variables.

Los tres métodos descritos tienen el mismo objetivo general: evitar que diferencias de escala alteren la geometría del espacio de características. Sin embargo, utilizan distintos valores de referencia para realizar la transformación.

- Z-Score utiliza la media y la desviación estándar.
- Min-Max utiliza el valor mínimo y máximo observados.
- Robust Scaling utiliza la mediana y el rango intercuartílico.


La elección del método depende de las características de los datos, particularmente de la presencia de valores atípicos y del comportamiento esperado de los algoritmos que se aplicarán posteriormente.

5. Transformaciones de distribución

En la sección anterior se estudiaron las transformaciones que tenían como objetivo modificar la escala de las variables. Sin embargo, incluso después de escalar los datos, puede existir otro problema importante: la forma de la distribución. Dos variables pueden encontrarse en escalas comparables y aun así presentar distribuciones muy diferentes. Por ejemplo, consideremos la variable ingreso mensual.

1000, 1200, 1300, 1500, 1800, 2000, 2500, 3000, 15000.

La mayoría de observaciones se concentra en valores relativamente bajos, mientras que unas pocas observaciones presentan valores mucho mayores. Esta situación genera una distribución desequilibrada, donde gran parte de los datos se concentra en una región del espacio de representación y unas pocas observaciones ocupan posiciones muy alejadas. Cuando esto ocurre, algunos algoritmos pueden tener dificultades para identificar patrones, estimar relaciones o construir representaciones visuales adecuadas. Por esta razón, en muchos problemas resulta conveniente transformar la distribución de una variable antes de realizar el análisis.



Una distribución es **simétrica** cuando los datos se distribuyen de forma aproximadamente equilibrada alrededor de una región central. Por ejemplo, las alturas de una población suelen presentar una distribución relativamente simétrica: existen personas más bajas y más altas que el promedio, pero ambas situaciones aparecen con frecuencias comparables.

Sin embargo, muchas variables reales no presentan este comportamiento. Ejemplos: ingresos económicos, número de seguidores en redes sociales, ventas de productos, número de visitas a una página web, concentraciones de contaminantes. Todas ellas suelen presentar unos pocos valores muy grandes y una gran cantidad de valores pequeños. Este fenómeno recibe el nombre de **asimetría**.

La asimetría positiva aparece cuando la distribución presenta una cola larga hacia los valores grandes. La mayoría de observaciones se concentra en valores pequeños, mientras que unas pocas observaciones se extienden hacia valores mucho mayores.

La asimetría negativa ocurre cuando la cola se extiende hacia los valores pequeños. La mayoría de observaciones se concentra en valores altos y unas pocas observaciones aparecen alejadas hacia valores bajos.

Una distribución muy asimétrica puede producir efectos no deseados:

- concentración excesiva de observaciones en una región;
- influencia desproporcionada de valores extremos;
- dificultad para visualizar patrones;

- deterioro de algunos modelos estadísticos que asumen distribuciones aproximadamente simétricas.

Por esta razón, en ocasiones resulta útil transformar la distribución. El objetivo no es eliminar información, sino construir una representación matemática más adecuada para el análisis.

5.1. Métodos.

a) Transformación logarítmica.

La transformación logarítmica es una de las técnicas más utilizadas para reducir asimetrías positivas. Se define como:

$$x' = \log(x + 1)$$

donde:

x = valor original.

x' = valor transformado.

La constante 1 se agrega para evitar problemas cuando existen valores iguales a cero.

La función logarítmica no modifica todos los valores de la misma manera. Los valores pequeños sufren cambios relativamente reducidos. Los valores grandes son comprimidos considerablemente.

Por ejemplo:

Valor original	Log(x+1)
10	2.40
100	4.61
1000	6.91
10000	9.21

Obsérvese que una diferencia de miles de unidades en la escala original se convierte en una diferencia mucho menor después de la transformación.

Desde la perspectiva del espacio de características, la transformación logarítmica acerca observaciones extremadamente alejadas y reduce la dominancia de valores muy grandes. Como consecuencia, las distancias entre observaciones suelen distribuirse de forma más equilibrada.

La transformación logarítmica suele emplearse cuando:

- la variable presenta asimetría positiva;
- existen valores muy grandes respecto al resto;
- todos los valores son mayores o iguales a cero.

b) Transformación Box-Cox

La transformación logarítmica funciona bien en muchos casos, pero no siempre produce la distribución más adecuada. La transformación Box-Cox generaliza la idea del logaritmo y permite ajustar automáticamente la intensidad de la transformación.

Se define como:

$$y(\lambda) = (y^\lambda - 1)/\lambda \quad \text{si } \lambda \neq 0$$

$$y(\lambda) = \log(y) \quad \text{si } \lambda = 0$$

donde:

y = valor original.

λ = parámetro de transformación.

El parámetro λ controla cuánto se modifica la distribución. Valores distintos de λ producen transformaciones distintas.

Por ejemplo:

- $\lambda = 1 \rightarrow$ prácticamente no transforma los datos.
- $\lambda = 0 \rightarrow$ equivale al logaritmo.
- $\lambda < 1 \rightarrow$ comprime los valores grandes.
- $\lambda > 1 \rightarrow$ expande ciertas regiones de la distribución.

Durante el proceso de ajuste, el algoritmo busca automáticamente el valor de λ que produce una distribución más cercana a la simetría.

Limitación: La transformación Box-Cox únicamente puede aplicarse cuando: $y > 0$. Es decir, todos los valores deben ser estrictamente positivos. Si existen ceros o valores negativos, la transformación no puede utilizarse directamente.

6. Transformación de variables categóricas

Hasta ahora hemos trabajado principalmente con variables numéricas. Variables como edad, ingreso, temperatura o concentración de contaminantes pueden representarse mediante números y, por tanto, pueden incorporarse directamente al vector de características de una observación. Sin embargo, muchos conjuntos de datos contienen variables categóricas, es decir, variables cuyos valores representan categorías o clases en lugar de magnitudes numéricas.

Por ejemplo:

Estudiante	Carrera
E001	Ingeniería
E002	Medicina
E003	Derecho

En este caso, la variable "Carrera" describe una característica importante de los estudiantes, pero sus valores son etiquetas textuales.

Recordemos que una observación se representa mediante un vector de características y que los algoritmos operan matemáticamente sobre dichos vectores. Por ejemplo, una observación podría representarse como: (20, 15.3, 92), donde los valores corresponden a edad, promedio y asistencia.

Los algoritmos pueden calcular:

- distancias;
- similitudes;
- medias;
- varianzas;
- correlaciones;

porque todas las componentes del vector son valores numéricos. Ahora supongamos que incorporamos la variable carrera: (20, 15.3, 92, Ingeniería). Aparece un problema inmediato.

- ¿Qué significa sumar Ingeniería + Medicina?
- ¿Qué significa calcular el promedio entre Derecho y Ingeniería?
- ¿Qué distancia existe entre Medicina y Arquitectura?

Estas operaciones no poseen significado matemático.

Por esta razón, antes de incorporar variables categóricas al espacio de características es necesario transformarlas en representaciones numéricas.

El objetivo de esta transformación no es cambiar el significado de las categorías, sino construir una representación matemática que preserve la información contenida en ellas.

6.1 Métodos.

a) One-Hot Encoding

One-Hot Encoding es el método más utilizado cuando las categorías no poseen un orden natural. Es decir, no existe una relación de mayor o menor entre estas categorías. En estos casos se crea una nueva variable binaria para cada categoría.

Salario	Altura	Animal	Compra
2630.00	170	Gato	0
56500.00	169	Perro	1
1250.00	185	Pez	1
8900.00	176	Perro	0

Salario	Altura	Animal Gato	Animal Perro	Animal Pez	Compra
2630.00	170	1	0	0	0
56500.00	169	0	1	0	1
1250.00	185	0	0	1	1
8900.00	176	0	1	0	0

Cada categoría pasa a convertirse en una dimensión independiente dentro del espacio de características. De esta forma ninguna categoría recibe artificialmente un valor mayor o menor que otra.

b) Ordinal Encoding

Existen situaciones donde las categorías sí poseen un orden natural.

Por ejemplo:

Nivel educativo
Primaria
Secundaria
Universidad
Posgrado

Aquí existe una jerarquía evidente. Primaria representa un nivel educativo inferior a Secundaria. Secundaria representa un nivel inferior a Universidad. En estos casos puede utilizarse Ordinal Encoding.

La transformación asigna un número entero a cada categoría respetando el orden existente.

Categoría	Código
Primaria	0
Secundaria	1
Universidad	2
Posgrado	3

La codificación no indica una cantidad exacta. El valor numérico únicamente representa la posición de la categoría dentro de una secuencia ordenada.

Lo importante es preservar la relación:

Primaria < Secundaria < Universidad < Posgrado

Ordinal Encoding no debe aplicarse cuando las categorías carecen de orden natural.

Por ejemplo:

- ciudades;
- carreras universitarias;
- colores;
- países.

Asignar números a estas categorías introduciría relaciones inexistentes en los datos.

c) Target encoding

En algunos problemas aparecen variables categóricas con cientos o miles de categorías distintas. Por ejemplo: código postal; identificador de producto; nombre de empresa; distrito de residencia.

Aplicar One-Hot Encoding en estas situaciones puede generar cientos o miles de nuevas variables, incrementando considerablemente la dimensionalidad del espacio de características. Para abordar este problema se utiliza Target Encoding.

Target Encoding reemplaza cada categoría por una estadística calculada a partir de la variable objetivo.

Supongamos un problema de predicción donde deseamos estimar si un estudiante aprueba un curso. La variable objetivo puede tomar:

- Aprobó = 1
- No aprobó = 0

Consideremos la siguiente información histórica:

Carrera	Aprobó
Ingeniería	1
Ingeniería	1
Ingeniería	0
Medicina	1
Medicina	1
Derecho	0
Derecho	0

Calculamos el promedio de aprobación para cada carrera.

Ingeniería:

$$(1 + 1 + 0) / 3 = 0.67$$

Medicina:

$$(1 + 1) / 2 = 1.00$$

Derecho:

$$(0 + 0) / 2 = 0.00$$

La transformación produce:

Carrera	Valor codificado
Ingeniería	0.67
Medicina	1.00
Derecho	0.00

El valor asignado ya no representa una categoría. Representa el comportamiento histórico asociado a esa categoría respecto a la variable objetivo.

Por ejemplo: 0.67 significa que aproximadamente el 67% de los estudiantes de esa categoría aprobaron en los datos históricos.

Limitación: Target Encoding utiliza información de la variable objetivo para construir la transformación. Por esta razón existe riesgo de sobreajuste. Si la codificación se calcula

incorrectamente, el modelo puede memorizar patrones específicos del conjunto de entrenamiento y producir resultados poco fiables sobre datos nuevos.

Por ello, Target Encoding suele acompañarse de procedimientos de validación y regularización que reduzcan este riesgo.

La elección del método adecuado depende de la naturaleza de la categoría:

- One-Hot Encoding cuando las categorías no poseen orden.
- Ordinal Encoding cuando existe una jerarquía natural.
- Target Encoding cuando existe una gran cantidad de categorías y se dispone de una variable objetivo supervisada.

7. Transformación de variables temporales

Las variables de fecha y hora contienen información rica y multidimensional que debe descomponerse en atributos numéricos para ser aprovechada: año, mes, día, hora, día de la semana, trimestre, estación del año.

Variables cíclicas. Un problema particular surge con atributos que poseen naturaleza circular: el mes 12 (diciembre) y el mes 1 (enero) son temporalmente adyacentes, pero numéricamente distantes si se representan como enteros (12 vs. 1). La diferencia euclidiana entre ellos sería 11, cuando en realidad la distancia temporal es 1. Para preservar esta estructura cíclica se emplean transformaciones trigonométricas:

$$x_{\sin} = \sin(2\pi \cdot x / T), \quad x_{\cos} = \cos(2\pi \cdot x / T)$$

donde T es el período de la variable cíclica (T = 12 para meses, T = 7 para días de la semana, T = 24 para horas).

La transformación seno-coseno convierte una variable temporal en un punto sobre una circunferencia. Cada posición del ciclo ocupa una ubicación angular diferente.

Por ejemplo:

- las horas del día se distribuyen sobre una circunferencia de 24 posiciones;
- los días de la semana sobre una circunferencia de 7 posiciones;
- los meses del año sobre una circunferencia de 12 posiciones.

Como consecuencia, los valores temporalmente cercanos permanecen próximos dentro del espacio de características.

La transformación temporal permite representar explícitamente: tendencias; estacionalidades; ciclos; periodicidades; duración entre eventos.

Desde la perspectiva geométrica, estas transformaciones modifican la forma en que las observaciones se distribuyen dentro del espacio de características, permitiendo que algoritmos de agrupamiento, clasificación, reducción de dimensionalidad y análisis visual identifiquen estructuras temporales que permanecerían ocultas si únicamente se utilizara la fecha original. Por esta razón, la transformación de variables temporales constituye una etapa fundamental en la construcción de representaciones matemáticas adecuadas para el análisis de fenómenos dinámicos.

8. Transformación de texto

Los datos textuales requieren transformaciones específicas para ser representados como vectores numéricos en el espacio de características.

- **Bag of Words (BoW).** Representa cada documento como un vector de frecuencias de palabras. Si el vocabulario tiene V términos únicos, cada documento se convierte en un vector en $\mathbb{R}^V$. Es

un modelo computacionalmente simple pero pierde toda información sobre el orden y la semántica de las palabras.

- **TF-IDF (Term Frequency–Inverse Document Frequency)**. Pondera cada término por su frecuencia en el documento (TF) multiplicada por la inversa del logaritmo de su frecuencia en el corpus (IDF): $TF\text{-}IDF(t, d) = TF(t, d) \times \log(N / df(t))$, donde N es el número total de documentos y $df(t)$ es el número de documentos que contienen el término t . Reduce la importancia de términos muy frecuentes en el corpus (como artículos y preposiciones) y aumenta la de términos discriminativos.
- **Embeddings (representaciones vectoriales densas)**. Modelos como Word2Vec, FastText y BERT generan representaciones vectoriales densas en $\mathbb{R}^d$ (típicamente $d \in \{50, 100, 300, 768\}$) que capturan relaciones semánticas entre palabras. Palabras con significados similares se encuentran próximas en este espacio vectorial, propiedad que BoW y TF-IDF no pueden capturar.

9. Valores atípicos

Hasta ahora hemos visto que cada observación puede representarse como un punto dentro del espacio de características. La mayoría de observaciones suelen concentrarse en determinadas regiones de dicho espacio, formando patrones relativamente estables.

Sin embargo, en algunos casos aparecen observaciones cuyas características difieren considerablemente de las observaciones restantes. Estas observaciones reciben el nombre de **valores atípicos** o **outliers**.

De manera general, un valor atípico es una observación cuyos valores son inusuales respecto al comportamiento predominante observado en el conjunto de datos.

Por ejemplo, supongamos que registramos las horas de estudio semanales de un grupo de estudiantes:

Estudiante	Horas de estudio
E001	12
E002	15
E003	18
E004	14
E005	16
E006	120

La mayoría de observaciones se concentra entre 12 y 18 horas semanales, mientras que una observación presenta 120 horas.

Esta observación merece atención porque se encuentra muy alejada del comportamiento observado en el resto de los datos.

Desde la perspectiva del espacio de características, un valor atípico corresponde a una observación ubicada lejos de la región donde se concentra la mayor parte de los datos.

La identificación de outliers está estrechamente relacionada con conceptos como:

- distancia;
- densidad;
- vecindad;
- agrupamiento.

La presencia de un valor atípico no implica necesariamente que exista un error.

Las causas pueden ser muy diferentes.

- **Errores de medición**. El valor puede haberse generado por fallas en sensores, instrumentos o sistemas de captura.

Por ejemplo:

- temperatura registrada como 850 °C debido a un sensor defectuoso;
- edad registrada como 250 años;
- concentración negativa de contaminantes.

En estos casos el valor no representa el fenómeno real.

- **Errores de registro o digitación.** El dato puede haberse introducido incorrectamente.

Por ejemplo:

- escribir 50000 en lugar de 5000;
- registrar 120 horas de estudio cuando debían ser 12.

- **Eventos raros pero reales.** Algunos fenómenos producen observaciones extremas que efectivamente ocurrieron.

Por ejemplo:

- una ola de calor excepcional;
- una crisis financiera;
- una concentración inusualmente alta de contaminantes;
- una precipitación extrema.

Aunque estas observaciones sean poco frecuentes, forman parte del fenómeno estudiado.

Algunas observaciones representan comportamientos genuinamente diferentes.

Por ejemplo:

- un estudiante con rendimiento extraordinario;
- un cliente con gastos excepcionalmente altos;
- un atleta de élite.

Estos casos también constituyen información válida.

Los valores atípicos pueden modificar significativamente la representación matemática de los datos.

Por ejemplo, algunos valores estadísticos son sensibles a valores extremos:

- media;
- varianza;
- desviación estándar;
- correlación de Pearson.

Asimismo, muchos algoritmos utilizan distancias para comparar observaciones. Cuando existe una observación extremadamente alejada, puede alterar la geometría del espacio de características y modificar los resultados obtenidos. Sin embargo, esto no significa que deba eliminarse automáticamente. La cuestión fundamental no es si el valor es extremo, sino si representa correctamente el fenómeno estudiado.

Uno de los errores más comunes consiste en asumir que: "todo valor atípico debe eliminarse." Esta afirmación es incorrecta. Un valor atípico puede contener información extremadamente relevante. Por ejemplo, si estamos estudiando contaminación atmosférica, precisamente los episodios extremos suelen ser los eventos de mayor interés científico. Eliminar dichas observaciones podría producir una representación incompleta del fenómeno. Por esta razón, la primera pregunta siempre debe ser:

¿El valor representa un error o representa una observación real?

La respuesta depende del conocimiento del dominio y no únicamente de criterios estadísticos.

Estrategias de tratamiento de los valores atípicos:

- a) **Eliminación.** La eliminación consiste en descartar la observación del conjunto de datos. Esta estrategia únicamente es apropiada cuando existe evidencia razonable de que el valor fue generado por un error de medición, captura o registro.

Por ejemplo:

- edad = 300 años;
- temperatura = -500 °C;
- concentración negativa de partículas.

Si el valor corresponde a un fenómeno real, eliminarlo implica perder información.

- b) **Conservación.** Cuando la observación representa un comportamiento real del fenómeno, generalmente debe conservarse.

Por ejemplo:

- un episodio extremo de contaminación;
- una venta excepcionalmente alta;
- una precipitación extraordinaria.

Aunque dichas observaciones sean poco frecuentes, forman parte de la realidad que se desea estudiar.

- c) **Winsorización.** En algunos casos no se desea eliminar la observación, pero sí reducir la influencia de valores extremadamente grandes o pequeños. La winsorización reemplaza los valores extremos por límites previamente definidos.

Por ejemplo:

- valores menores al percentil 1 se sustituyen por el valor del percentil 1;
- valores mayores al percentil 99 se sustituyen por el valor del percentil 99.

La observación permanece en el conjunto de datos, pero su impacto sobre determinados cálculos se reduce.

- d) **Robust Scaling.** Otra alternativa consiste en transformar la variable utilizando medidas menos sensibles a valores extremos. Recordemos que la estandarización Z-Score utiliza: media y desviación estándar. Ambos estadísticos pueden verse afectados por observaciones extremas.

Robust Scaling utiliza:

- mediana;
- rango intercuartílico (IQR).

Como estas medidas son menos sensibles a los valores extremos, la transformación resultante reduce la influencia de los outliers sin eliminarlos.

Es importante destacar que Robust Scaling no elimina observaciones ni corrige errores. Simplemente modifica la escala utilizada para representar la variable.

Implicaciones para el análisis visual: Los valores atípicos afectan directamente la geometría del espacio de características.

Dependiendo de su magnitud pueden:

- expandir artificialmente ciertas regiones del espacio;
- modificar distancias entre observaciones;
- influir en agrupamientos;
- alterar proyecciones obtenidas mediante PCA, MDS, t-SNE o UMAP;
- afectar la interpretación visual de patrones.

Por esta razón, antes de aplicar técnicas de análisis visual resulta fundamental comprender el origen de los valores atípicos y decidir cuidadosamente cómo serán tratados.

La decisión correcta no depende únicamente de la estadística, sino también del conocimiento del fenómeno que se desea representar.